张家瑞

jiarui-z23@mails.tsinghua.edu.cn | +86 189 2512 1908 | ezoicoder.github.io

个人概述：我是清华大学**姚班**四年级本科生，主要关注 **AI 基础设施**与 **机器学习系统**，致力于为大模型训练与推理构建高性能、可扩展的系统。

教育背景

清华大学，北京 2023 年 9 月—2027 年 6 月（预计）
计算机科学与技术工学学士，交叉信息研究院
GPA: 3.8/4.0 | TOEFL iBT: 5.5/6.0

经历

本科生研究 2026 年 8 月—至今
清华大学张景昭教授指导
- 为正则语言和马尔可夫链构造 randomized-AC^0 采样器。
- 证明 revision 能够降低扩散语言模型的串行计算量。

研究实习生 2026 年 1 月—2026 年 8 月
袁彬航课题组，香港科技大学
- 开发面向 **Tree Attention** 的分布式训练方法，降低显存占用并提升多轮 LLM 训练吞吐量。
- 参与 D^2**SD** 双扩散草稿模型研究，通过推测解码加速大语言模型推理。

研究实习生 2025 年 10 月—2025 年 12 月
吴翼课题组，清华大学
- 参与开发支持可扩展训练的 **serverless** 强化学习平台。

应用研究实习生 2025 年 7 月—2025 年 9 月
腾讯 CDG
- 为金融大语言模型设计模型打分与提示词驱动的奖励评分方法，围绕引用有效性、内容准确性、时效性与指令遵循能力构建评测流程。
- 将引用格式准确率由 40% 提升至 98%，内容与时效性准确率由 78% 提升至 97%，IFEval 准确率由 38% 提升至 80%。

论文发表

- **Jiarui Zhang***, Yuchen Yang*, Ran Yan*, Zhiyu Mei, Liyuan Zhang, Daifeng Li, Wei Fu, Jiaxuan Gao, Shusheng Xu, Yi Wu, Binhang Yuan. "AREAL-DTA: Dynamic Tree Attention for Efficient Reinforcement Learning of Large Language Models." **ICML 2026**.
- Liyuan Zhang, **Jiarui Zhang**, Jinwei Yao, Ran Yan, Yuchen Yang, Jiahao Zhang, Tongkai Yang, Yi Wu, Binhang Yuan. "D^2SD: Accelerating Speculative Decoding with Dual Diffusion Draft Models." arXiv:2606.04446.
- **Jiarui Zhang***, Chengwei Liang*, Haozhe Jiang, Binhang Yuan, Jingzhao Zhang. "Revision Provably Reduces Sequential Computation in Diffusion Language Models." Zenodo preprint, 2026.

* 共同一作。

荣誉

- **2021 年全国青少年信息学奥林匹克竞赛（NOI 2021）**——金牌
- **NOI 2022 广东省队选拔**——第 1 名

兴趣爱好

- 毽球，清华大学毽球队队员
- 徒步（喜欢单日爬升约 1000 m 的路线）