

张家瑞

jiarui-z23@mails.tsinghua.edu.cn | +86 189 2512 1908 | ezoicoder.github.io

个人概述: 我是清华大学姚班四年级本科生, 主要关注 **AI infrastructure** 与 **ML systems**, 致力于为大模型训练与推理构建高性能、可扩展的系统。同时, 我也关注**理论计算机科学**, 尤其希望探索如何利用 AI 工具推动该领域的发展。

教育背景

清华大学, 北京
计算机科学与技术工学学士, 交叉信息研究院
GPA: 3.78/4.0 | TOEFL iBT: 5.5/6.0

2023 年 9 月—2027 年 6 月 (预计)

经历

本科生研究

清华大学张景昭教授指导

2026 年 8 月—至今

[博客文章](#) ↗

- 研究扩散语言模型对正则语言输入输出对分布的采样, 证明允许 revision 时至多两轮即可完成采样, 而对于不属于 AC^0 的正则语言, 无 revision 时需要 $\Theta(\log n / \log \log n)$ 轮。
- 构造对 Markov 轨迹进行采样的 randomized- AC^0 电路。

研究实习生

袁彬航课题组, 香港科技大学

2026 年 1 月—2026 年 8 月

- 开发面向 **Tree Attention** 的分布式训练方法, 降低显存占用并提升多轮 LLM 训练吞吐量。
- 参与 D^2SD 双扩散草稿模型研究, 通过投机采样加速大语言模型推理。

研究实习生

吴翼课题组, 清华大学

2025 年 10 月—2025 年 12 月

- 参与开发支持可扩展训练的 **serverless** 强化学习平台。

应用研究实习生

腾讯 CDG

2025 年 7 月—2025 年 9 月

- 为金融大语言模型设计模型打分与提示词驱动的奖励评分方法, 围绕引用有效性、内容准确性、时效性与指令遵循能力构建评测流程。
- 将引用格式准确率由 40% 提升至 98%, 内容与时效性准确率由 78% 提升至 97%, IFEval 准确率由 38% 提升至 80%。

论文发表

- Jiarui Zhang***, Yuchen Yang*, Ran Yan*, Zhiyu Mei, Liyuan Zhang, Daifeng Li, Wei Fu, Jiaxuan Gao, Shusheng Xu, Yi Wu, Binhang Yuan. "AREAL-DTA: Dynamic Tree Attention for Efficient Reinforcement Learning of Large Language Models." **ICML 2026**.
- Liyuan Zhang, **Jiarui Zhang**, Jinwei Yao, Ran Yan, Yuchen Yang, Jiahao Zhang, Tongkai Yang, Yi Wu, Binhang Yuan. " D^2SD : Accelerating Speculative Decoding with Dual Diffusion Draft Models." arXiv:2606.04446.

* 共同一作。

荣誉

- 2021 年全国青少年信息学奥林匹克竞赛 (NOI 2021) ——金牌
- NOI 2022 广东省队选拔——第 1 名

兴趣爱好

- 毽球, 清华大学毽球队队员
- 徒步 (喜欢单日爬升约 1000 m 的路线)