

张家瑞

电话: +86 189 2512 1908
邮箱: jiarui-z23@mails.tsinghua.edu.cn
个人主页: ezoicoder.github.io

个人概述

我是清华大学姚班四年级本科生, 主要关注 **AI infrastructure** 与 **ML systems**, 致力于为大模型训练与推理构建高性能、可扩展的系统。同时, 我也关注**理论计算机科学**, 尤其希望探索如何利用 AI 工具推动该领域的发展。

教育背景

清华大学, 北京
人工智能工学学士, 交叉信息研究院
GPA: 3.78/4.0 (36/91)
TOEFL iBT: 5.5/6.0

2023 年 9 月 – 2027 年 6 月 (预计)

实习经历

研究实习生, 袁彬航课题组, 香港

2026 年 1 月 – 至今

- 开发面向 **Tree Attention** 的分布式训练系统, 降低显存占用, 提升多轮 LLM 训练的吞吐量。

研究实习生, 吴翼课题组, 北京

2025 年 10 月 – 2025 年 12 月

- 参与开发支持可扩展训练的 **serverless** 强化学习平台。

应用研究实习生, 腾讯 CDG, 深圳

2025 年 7 月 – 2025 年 9 月

- 基于 **verl** 强化学习框架, 提升金融大语言模型的 **instruction-following** 能力; 实现 **model-based** 方法, 并构建基于 **prompt-engineering-driven** 的奖励评分机制, 显著改善业务指标。
- 成果: 引用格式准确率由 40% 提升至 98%; 内容准确率及时效性准确率由 78% 提升至 97%; 通用 instruction-following 基准 IFEval 准确率由 38% 提升至 80%。

论文发表

- Jiarui Zhang*, Yuchen Yang*, Ran Yan*, Zhiyu Mei, Liyuan Zhang, Daifeng Li, Wei Fu, Jiaxuan Gao, Shusheng Xu, Yi Wu, Binhang Yuan. *AREAL-DTA: Dynamic Tree Attention for Efficient Reinforcement Learning of Large Language Models*. **ICML 2026 Accepted**
- Liyuan Zhang, Jiarui Zhang, Jinwei Yao, Ran Yan, Yuchen Yang, Jiahao Zhang, Tongkai Yang, Yi Wu, Binhang Yuan. *D²SD: Accelerating Speculative Decoding with Dual Diffusion Draft Models*. **arXiv preprint**

荣誉奖项

- 2021 年全国青少年信息学奥林匹克竞赛 (NOI 2021) — 金牌

兴趣爱好

毽球 (清华大学毽球队队员)
徒步 (初学者, 喜欢单日爬升约 1000m 的路线)